神经机器翻译实战 - 参加一次比赛

肖桐 朱靖波

xiaotong@mail.neu.edu.cn
zhujingbo@mail.neu.edu.cn

东北大学 自然语言处理实验室 http://www.nlplab.com



• 一个小白入门神经机器翻译的经历

找一些数据, 跑一下系 上网看视频, 找博 客,阅读一些书籍 统, 有结果! 耶! 我喜欢NLP和MT. 学各种深度学习 尝试下 开源框架, 阅读开 源NMT系统代码

• 一个小白入门神经机器翻译的经历



• 一个小白入门神经机器翻译的经历



• 小白白还想成为大白,甚至大白白、大大白,还是使用同样的套路。

(博客、书、实验)×10

• 一个小白入门神经机器翻译的经历

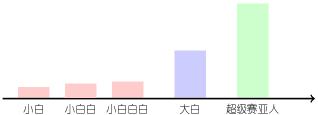


小白白还想成为大白,甚至大白白、大大白,还是使用同样的套路。但是,只是变得更白了,离大白还很远!

(博客、书、实验)×10









- 搞了半天,还是个入门选手,当遇到很多问题时还是无从下手
 - ▶ 论文写不出来,没有idea
 - ▶ 实验一弄就不好使,性能就是不涨
 - ▶ 自己搭的系统还很挫,离谷歌翻译还很遥远

实力表



- 搞了半天. 还是个入门选手. 当遇到很多问题时还是无 从下手
 - ▶ 论文写不出来,没有idea
 - ▶ 实验一弄就不好使,性能就是不涨
 - ▶ 自己搭的系统还很挫, 离谷歌翻译还很谣远
- 原因很简单: 我们使用的系统还很初级, 离state-of-the-art有距离,导致视野也会受限。
 - 怎么办?参加一次比赛吧

Towards State-of-the-Art

注意,机器翻译终究是面向应用的研究领域。因此,研发高性能的系统是我们追求的目标。一般来说,影响机器翻译系统性能有几个因素

● 数据:大规模、高质量的数据是前提

② 技术: 算法和模型要足够先进

1 打磨:需要对各个模块进行细致的打磨,说白了,下功夫不到有数据和技术也是白搭

Towards State-of-the-Art

- 注意,机器翻译终究是面向应用的研究领域。因此,研发高性能的系统是我们追求的目标。一般来说,影响机器翻译系统性能有几个因素
 - 数据:大规模、高质量的数据是前提
 - ② 技术: 算法和模型要足够先进
 - **③ 打磨**: 需要对各个模块进行细致的打磨,说白了,下功夫 不到有数据和技术也是白搭
- 参加一次机器翻译的评测比赛是实现上述目标的一个很好的方法,比如,WMT News Translation Track
 - 评测提供数据,规模和质量都能保证,因此可以在相对公 平的数据基础上进行技术对比
 - ② 评测系统都会有技术报告,因此可以相对容易的复现以前的结果,而且很容易了解最新的动态
 - ③ 评测本身就是驱动力(大家都希望取得好成绩),因此会不断打磨细节

基本流程

- 机器翻译比赛现在已经非常友好了 (如WMT、CCMT等),有些比赛甚至都不需要提前报 名. 注册个账户就可以刷榜
 - 从官方网站了解比赛计划
 - ② 发放训练数据
 - ◎ 数据初级及加工
 - 洗型. 搭建第一个初级版本
 - 和自己较劲(如果能够对比以前的参赛系统就更好了)。 改讲系统,尝试各种技术
 - 发放测试数据,运行系统提交最终结果
 - ◎ 公布结果
 - ❸ 撰写评测报告
 - 参加评测研讨会,学习交流

基本流程

- 机器翻译比赛现在已经非常友好了 (如WMT、CCMT等),有些比赛甚至都不需要提前报 名,注册个账户就可以刷榜
 - 从官方网站了解比赛计划
 - ② 发放训练数据
 - ◎ 数据初级及加工
 - 选型, 搭建第一个初级版本
 - 和自己较劲(如果能够对比以前的参赛系统就更好了), 改进系统,尝试各种技术
 - 发放测试数据,运行系统提交最终结果
 - ◎ 公布结果
 - ◎ 撰写评测报告
 - ❷ 参加评测研讨会,学习交流
- 当然,这里并不是要描述整个机器翻译的流程。我们重点还是关注有哪些技术可以使神经机器翻译变得更强,为相关研究提供合理的基线系统

必要的准备 - 选型

- 这里我们以WMT、CCMT的汉英新闻翻译任务为例,介绍如何搭建一套性能更加强劲的神经机器翻译系统
 - ▶ 翻译品质为评价指标(如BLEU),翻译速度等暂不考虑
 - ▶ 假设设备是充分的
 - ▶ 假设开发系统和模型训练时间也是充分的

必要的准备 - 选型

- 这里我们以WMT、CCMT的汉英新闻翻译仟务为例。介 绍如何搭建一套性能更加强劲的神经机器翻译系统
 - ▶ 翻译品质为评价指标 (如BLEU) , 翻译速度等暂不考虑
 - ▶ 假设设备是充分的
 - ▶ 假设开发系统和模型训练时间也是充分的
- 面临的一个问题是选择什么样的系统架构。当然. 这个 问题可以边做表调整,不过这里我们选择Transformer作 为基本框架(见第六章)。因为,
 - ▶ Transformer已经被证明是当今性能最好的NMT模型之一
 - ▶ 在WMT2019和CCMT2019的评测中. Transformer已经成为 了各个参赛队伍的标配
 - ▶ Transformer是很多benchmark上的优胜者

必要的准备 - 选型

- 这里我们以WMT、CCMT的汉英新闻翻译任务为例,介绍如何搭建一套性能更加强劲的神经机器翻译系统
 - ▶ 翻译品质为评价指标(如BLEU),翻译速度等暂不考虑
 - ▶ 假设设备是充分的
 - ▶ 假设开发系统和模型训练时间也是充分的
- 面临的一个问题是选择什么样的系统架构。当然,这个问题可以边做表调整,不过这里我们选择Transformer作为基本框架(见第六章)。因为,
 - ▶ Transformer已经被证明是当今性能最好的NMT模型之一
 - ► 在WMT2019和CCMT2019的评测中,Transformer已经成为了各个参赛队伍的标配
 - ▶ Transformer是很多benchmark上的优胜者
- 当然,后面讨论的内容绝大多数与神经机器翻译架构无关,这些可以被推广到其它类型的系统上
 - ▶ 基础技术:确保可以得到一个不太差的系统
 - ▶ 进阶技术:接近甚至达到State-of-the-art

Outline

基础技术

- 1. 数据处理
- 2. 翻译单元切分
- 3. 正则化
- 4. 多模型集成
- 5. 自左向右解码 vs. 自右向左解码
- 6. 翻译长度控制
- 7. 大模型和大批量训练

讲阶技术

- 1. 深层模型
- 2. 单语数据的使用
- 3. 知识精炼
- 4. 双向训练
- 5. 统计机器翻译的使用

 双语数据的质量和数量对于训练一个神经机器翻译系统 至关重要,有时即使拥有海量的数据,但是质量较差仍 然会损失机器翻译的性能

		BLEU	
数据设置	数据量	英-德	德-英
初始数据	3M	32.5	31
+未处理额外数据	38M	26.6	32.7
+处理后数据	7M	37.9	37.5

• 数据处理便是对已有的数据集进行筛选处理的过程,一般的流程为:



- 神经机器翻译以词为单位处理句子序列,因此需要对以句子为单位的数据切分。
 - 以词表示的语言如英语,主要处理标点符号的粘连和短语的划分
 - ▶ 中文,日语等无明显词界限的语种,则需要特殊的处理。

中文:神经机器翻译改变了我们的生活。

英文: Neural machine translation has changed our lives.



中文:神经 机器 翻译 改变 了 我们 的牛活。

英文: Neural machine translation has changed our lives.

• 常用的分词工具包括: mose, niutrans分词。。。

- 符号标准化: 统一源语目标语中的标点符号。
- 数据过滤是指过滤低质量数据,过滤的手段主要包括:
 - ▶ 重复数据过滤、乱码过滤、长度比过滤、HTML标签过滤、 流畅度过滤。。。

源语	目标语
天气 好 但	The weather today is good , but
我喜欢下雨 天。	I like rainy days 。
显示 所选 的 面 。 <\p>	$<\!\!p\!\!>\!\!to$ show the selected side . $<\!\!\setminus p\!\!>$
桃树 、 杏树 、 梨树 , 你 不让 我 , 我 不让 你 , 都 开满 了 花 。	Flowers bloom .
机器 翻译 给 人们 的 牛活 带来了 便利 。	Machine translation brings convenience to people's
机器 翻译 钻 人们 即 生冶 忧未) 使利。	lives.
这件事情的成功率为 50 o/o。	The success rate for this matter is 50 $\ensuremath{\text{o}}/\ensuremath{\text{o}}$.
翻译 对 我 特别 感兴趣 。	I'm interested in translation .
他说 : "这个 深深 有趣 的 想法 印 在	He said: , , This interesting idea is deeply
我 心里 。"	imprinted in my heart. , ,
我喜欢下雨 天。	I like rainy days 。
花下 成千成百 的 蜜蜂 嗡嗡 地 闹着 。	Hundreds of bees hummed under the flowers .

- 符号标准化: 统一源语目标语中的标点符号。
- 数据过滤是指过滤低质量数据,过滤的手段主要包括:
 - ▶ 重复数据过滤、乱码过滤、长度比过滤、HTML标签过滤、 流畅度过滤。。。

源语	目标语
天气 好 但	The weather today is good , but
我喜欢下雨 天 。	I like rainy days
显示 所选 的 面 。 <\p>	$<\!\!p\!\!>\!\!to$ show the selected side . $<\!\!\setminus p\!\!>$
桃树 、 杏树 、 梨树 , 你 不让 我 , 我 不让 你 , 都 开满 了 花 。	Flowers bloom .
	Machine translation brings convenience to people's
机器 翻译 给 人们 的 生活 带来了 便利 。 	lives.
这件事情的成功率为50%。	The success rate for this matter is 🦷 ·
翻译 对 我 特别 感兴趣 。	I'm interested in translation .
他说 : "这个深深有趣的想法印在	He said: " This interesting idea is deeply
我心里。"	imprinted in my heart. "
我喜欢下雨 天 。	I like rainy days
花下 成千成百 的 蜜蜂 嗡嗡 地 闹着 。	Hundreds of bees hummed under the flowers .

- 符号标准化: 统一源语目标语中的标点符号。
- 数据过滤是指过滤低质量数据,过滤的手段主要包括:
 - ▶ 重复数据过滤、乱码过滤、长度比过滤、HTML标签过滤、 流畅度过滤。。。



对于某些形态学丰富语言,比如英语,德语等,常用一个单词的不同形态表示不同的意思,这就导致一个单词因为不同形态会产生各种不同词,就造成了大词汇量问题。

以英语为例:

名词

cat, cats watch, watches baby, babies wife, wives

动词

do, did , does, doing, done have, had, has, having

- 大词汇量导致翻译系统需要更大的词表,构造更大的词向量矩阵。带来了两个问题:
 - ▶ 词汇表稀疏,低频词得不到充分的训练。
 - ▶ 计算量更大,更大词向量矩阵,造成了计算资源的浪费。

• 为了解决这个问题,提出了子词的概念。



- 将词分解为子词的方式有很多种, 主流的方法包括:
 - ▶ 字节对编码 (Byte Pair Encoding, BPE) 统计频次
 - ▶ Wordpiece 语言模型
 - ▶ Unigram Language Model 语言模型
- BPE算法最早用于压缩,后来在NLP领域得到推广,是目前最流行,最简单有效的方法。
- 子词切分,缩减词表大小,节省计算资源,提高性能。
- 一般设定BPE切分后的词表大小为32000。

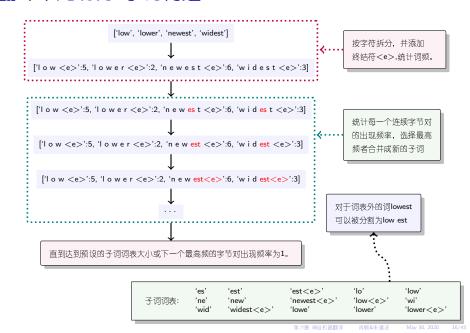
• 使用BPE切分的具体的流程如下:



- 在构建子词词表,应用BPE时存在两种方式:
 - ▶ 分别对源语和目标语构建子词词表,应用BPE。
 - ▶ 联合源语和目标语词表,称为Joint-BPE,可以增强源语和目标语的一致性。
- BPE能够有效减少词表大小,以及UNK的数量:

segmentation	# tokens	# types	# UNK
compound splitting	102 m	1 100 000	643
morfessor	109 m	544 000	237
hyphenation	186 m	404 000	230
BPE	112 m	63 000	0
BPE (joint)	111 m	82 000	32

翻译单元切分-子词构造



- 用构造的BPE词表, 重新对句子中的词进行切分:
 - ▶ 对子词词表按长度由大到小排序

BPE词表:

errrr<e> tain<e> moun est<e> the<e> the<e> a<e> est<e> the<e> the

- 用构造的BPE词表,重新对句子中的词进行切分:
 - ▶ 对子词词表按长度由大到小排序
 - ▶ 遍历子词词表,寻找是否有当前单词的子串,如有则进行替换切分

BPE词表:

errrr<e> tain<e> moun est<e> the<e> a<e>

原始序列: "this<e>","highest<e>","mountain<e>"

BPE切分: "<unk>","high","est<e>","moun","tain<e>"

- 用构造的BPE词表,重新对句子中的词进行切分:
 - ▶ 对子词词表按长度由大到小排序
 - ▶ 遍历子词词表,寻找是否有当前单词的子串,如有则进行替换切分
 - ▶ 对子词词表中不存在的序列,替换为<unk>

BPE词表: errrr<e> tain<e> moun est<e> high the<e> a<e>

- 用构造的BPE词表,重新对句子中的词进行切分:
 - ▶ 对子词词表按长度由大到小排序
 - ▶ 遍历子词词表,寻找是否有当前单词的子串,如有则进行替换切分
 - ▶ 对子词词表中不存在的序列,替换为<unk>

BPE词表: errrr<e> tain<e> moun est<e> high the<e> a<e>

```
原始序列: "this<e>","highest<e>","mountain<e>"

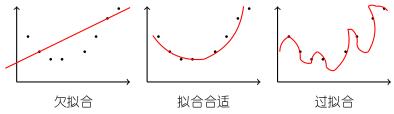
Local Control Con
```

机器翻译解码的句子由子词组成,需要进行BPE还原,将每个子词向后合并,直至遇到终结符

翻译结果: "moun","tain<e>" BPE还原: "mountain<e>"

正则化

• 神经机器翻译模型十分复杂, 由于观测数据的不充分, 及数据中存在的噪声,导致其求解十分不稳定,产生过 拟合的现象。



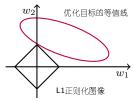
- 正则化是机器学习中的经典技术。通常用于缓解过拟合 问题,即模型参数过度拟合噪声数据,因此正则化也常被 称作降噪。
- 常用的正则化方法包括: 调整训练目标、标签平 滑、dropout。。。

正则化-优化训练目标

• 正则化的一种实现是在训练目标中引入一个正则项。在神经机器翻译中,引入正则项的训练目标为:

$$\widehat{\mathbf{w}} = \underset{\mathbf{w}}{\operatorname{argmin}} L(\mathbf{w}) + \lambda R(\mathbf{w})$$

- $L(\mathbf{w})$ 是损失函数,通过 λ 控制正则化项 $R(\mathbf{w})$ 的强度
- 常用的正则化项包括:
 - ▶ L1正则化: $R(\mathbf{w}) = ||\mathbf{w}||_1 = \sum_{w_i} |\mathbf{w}_i|$
 - ▶ L2正则化: $R(\mathbf{w}) = (||\mathbf{w}||_2)^2 = \sum_{w_i} w_i^2$



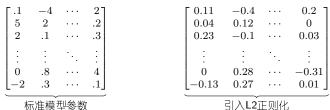
最优解外w1=0. L1下则化可以使参数矩阵更稀疏



切线处为最优解, L2正则化帮助缓解过拟合

正则化-优化训练目标

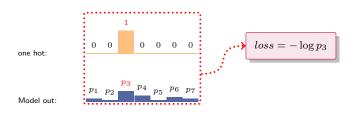
• 引入正则化项可以看作是使用了一种先验知识,使模型在求解时参数不会偏离0点太多,降低了模型的复杂度。



- 定义不同的正则化项, 使模型偏向于我们希望的方向。
 - ▶ 通过约束层输出差异,增强模型的表现力
 - ▶ 修正注意力的分布,使其更关注全局或局部的信息
 - ▶ 增加层之间的辅助损失加快模型收敛。。。
- 除了将正则化项与损失线性结合的方式,我们还可以通过调整标准答案的方式来引入先验知识,如标签平滑

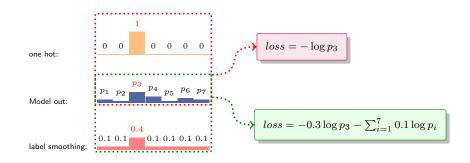
正则化-标签平滑

- 神经机器翻译系统对目标语的每个位置预测一个概率分布,表示词表中每个单词在该位置出现的可能性。
- 通过计算当前位置的分布与标准答案的差异作为损失
- 使用one-hot向量作为标准答案,不考虑类别间的相关性



正则化-标签平滑

- 神经机器翻译系统对目标语的每个位置预测一个概率分布,表示词表中每个单词在该位置出现的可能性。
- 通过计算当前位置的分布与标准答案的差异作为损失
- 使用one-hot向量作为标准答案,不考虑类别间的相关性
- label smoothing为所有位置分配了概率



正则化-标签平滑

- 可以看到, label smoothing不会独享所有的概率。
- 在考虑正确答案的同时,也考虑了类别之间的相关性, 提高了模型的泛化能力。
- 标签平滑的实现特别简单,只需要将真实答案独享的概率拿出一部分分享给所有的标签。

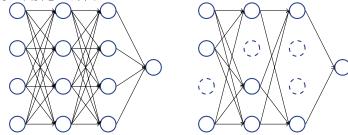
$$y_j^{\rm ls} = (1 - \alpha) \cdot \tilde{y}_j + \alpha \cdot q$$

• 其中 \tilde{y}_j 为对j位置预测时的真实分布,即one-hot向量,q则是在词表大小V上的均匀分布

$$(1-0.7)* \begin{bmatrix} 0.0\\0.0\\1.0\\0.0\\0.0\\0.0\\0.0\\0.0 \end{bmatrix} +0.7* \begin{bmatrix} 1/7\\1/7\\1/7\\1/7\\1/7\\1/7\\1/7 \end{bmatrix} = \begin{bmatrix} 0.1\\0.1\\0.4\\0.1\\0.1\\0.1\\0.1\\0.1\\0.1 \end{bmatrix}$$

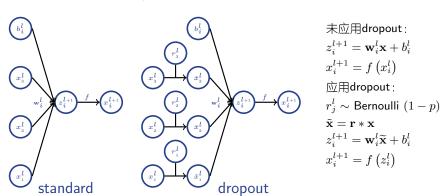
 α 表示分出去的概率大小 α 越大,得到的分布越软 更软的分布更适合作为目标分布,可以缓解数据中 噪声的影响

Dropout通过在每一次的迭代中,只激活一部分节点,屏蔽其他神经元。相当于每次迭代训练的都是不一样的网络,从而降低节点之间的关联性以及模型的复杂度,达到正则化的效果。



• 简单的说就是,在前向传播过程中,以一定的概率*p*激活神经元,使其不过于依赖某些特征,增强模型的泛化能力。

- Dropout的工作流程如下:
 - ▶ 以一定的概率*p*随机的激活隐藏层神经元,掩盖其他位置神经元
 - ▶ 得到输入后进行训练,更新被激活的的神经元参数
 - ▶ 恢复被掩盖的神经元,此时,被激活的神经元已经更新
 - ▶ 不断重复此过程,直到训练结束



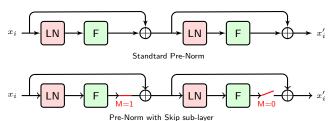
- 在实现中,我们常常用p来表示神经元被掩盖的几率
- 训练阶段,通过dropout的方式类似于训练了不同的网络
- 推断时为了结果的稳定性,无法随机丢弃神经元,需要对此进行补偿:
 - ▶ 推断时对每个神经元乘以概率p
 - ▶ 训练时,对激活的神经元以1/(1-p)进行放缩
- 推断时,激活全部的神经元类似于对很不同结构的网络进行集成,使互为"反向"的状态抵消缓解过拟合现象。
- 根据数据量和模型结构合理的设置p能够有效缓解过拟合问题,提升神经机器翻译的性能。



反向状态抵消

model	dropout	bleu
transformer-base	0	24.6
	0.1	25.8
	0.2	25.5
transformer-big	0.3	26.4

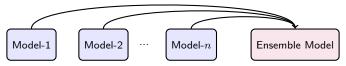
- dropout的思想同样可以应用在更高的维度,其中最常见的便是对模型结构的drop
- Transformer的结构由多层堆叠的编码解码层组成,残差 连接组合各层的输出,不同层之间会相互影响
- 在深层Transformer结构中,更容易导致过拟合的现象
- 我们可以借鉴dropout的思想,对子层结构进行drop



对层结构的dropout,能够有效缓解深层网络中的过拟合现象,提升模型性能

多模型集成

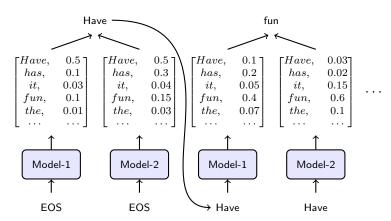
- 不同模型在训练的过程中的学习到的侧重而不一样。
 - ▶ 模型A: 短语翻译的好 ▶ 模型B: 单词翻译的好 ▶ 模型C: 句子流畅度更好
- 模型集成便是通过对多个翻译模型的结果进行融合。各 取所长, 提升件能。



- 如何构造多个候选模型:
 - 通过不同的随机种子进行初始化,增加模型的多样性
 - 构造不同的模型结构,比如,相对位置建模,动态层聚合...
 - ▶ 使用不同的数据集

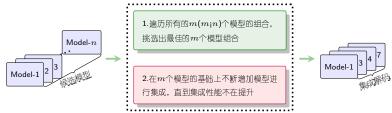
多模型集成

- 在机器翻译中如何实现多模型集成?
 - ▶ 检查点平均: 对单个模型训练不同时刻保存的参数状态进行平均
 - ▶ 预测分布平均: 对多个不同结构预测的概率分布进行平均



多模型集成

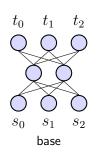
- 多模型的集成时,需要在众多的候选模型的选出最佳的集成组合。
 - ▶ 由于自回归特性,同时计算多个模型的概率分布,集成效率较慢,盲目尝试时间成本大。
 - ▶ 这里给出一种基于贪婪搜索的一种简单算法以便快速搜索 出优秀的模型组合进行集成:

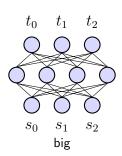


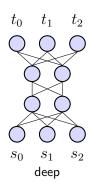
 不是模型越多,集成性能越好,搜索范围可根据时间和 计算成本确定

增大模型容量

- 模型容量与性能息息相关,在大规模的数据上训练时需要复杂的模型结构。
- 增大模型容量的方式主要包括:
 - ▶ 通过增大网络的隐层大小,即网络宽度
 - ▶ 增加网络的层数, 即网络深度
 - ▶ 增大输入和输出层,即更大的词表和词向量维度







大模型-big model

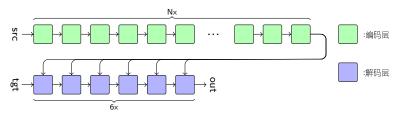
- 基于Transformer架构,我们增大其宽度的手段是使用Transformer-big模型。
- 通过增大模型的隐藏层大小,及输入输出层来提升模型容量,提升翻译品质。
- 除使用不同的参数设置外, transformer-base和big模型采用完全相同的网络结构。

	tranformer-base	transformer-big
词向量维度	512	1024
注意力头数	8	16
隐藏层维度	512	1024
FFN子层映射维度	2048	4096

采用transformer-big模型,同时针对不同的数据合理的调整学习率,dropout等参数,能够有效提升模型的性能。

大模型-deep model

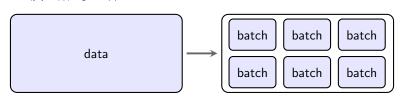
- 增大模型深度也是常用的提升模型容量的手段之一
- 对于transformer结构来说,增大模型深度指的是,增加 编码端的编码层个数



- 增大transformer模型的编码层深度,通过更多的线形及 非线形变换提升编码端的特称抽取能力。
- 单纯堆叠编码层,无法成功训练,通过合理的手段可以 训练50层,甚至100层的模型。

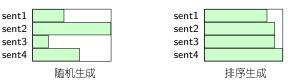
大批量训练及解码

- 在人脑对文本进行处理时,通常以句子为单位,机器翻译中则通过批量的方式处理文本
- 批量的方法即使通过一定的方式将多个句子组合成一个 批次送入模型
- 批量的方法可以用于模型的训练以及解码
 - 在训练时,同时输入多组源语和目标语,计算平均损失层,可以节省内存,加快收敛。
 - ▶ 解码时可以同时输入多句源语,得到一组译文,可以提高模型解码的效率



大批量-训练

- 逐句训练缓慢, 在提出批量方法之前一次性把所有样本 送入神经网络
 - ▶ 在整个语料库计算梯度,梯度方向更为准确
 - ▶ 大语料库导致内存爆炸,梯度间差异大难以使用全局学习 淧
- 如何合理构建batch十分重要,由于不同句子之间的长度 有明显的的差异,使用padding对空白位置填充
- 由于padding机制。随机的生成batch会导致padding过 名. 收敛缓慢, 对长度进行排序可有效缓解



• 除排序还有很多的策略用于batch生成,包括课程学习 等. 多种策略之间可以共同作用

大批量-训练

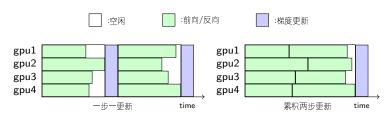
- 批量训练中一个重要的概念便是batch size,即每次送入模型的样本数量
- 除以句子作为度量单位外,常使用单词个数作为单位,batch size即为每次送入模型的单词个数
- 相比于句子的方式,进一步减少了padding数量,提高计算效率
- 实际中发现,训练时采用更大批量,配合更大的学习率,在加快模型收敛的同时有效提升了模型的性能。



batch	lr	BLEU
4096	0.01	29.15
8192	0.01	29.06
8192	0.02	29.49

大批量-训练

- 那么如何在有限的计算资源的情况下,增大batch size?
 - ▶ 多GPU以数据并行的方式分布式训练,同步更新,假设单块GPU容纳m个词,若拥有n块GPU,batch size便等于m*n
 - ▶ GPU的数量和内存受限时,可以采用累计梯度的方式
- 累计梯度是迭代多个批次,累积最终梯度进行更新
 - ▶ 累积n次,等价于batch size翻n倍
 - 减少设备间的通信,平衡多设备间运算差异,增大计算效率



大批量-解码

- 批量的方法同样可以应用于解码阶段。提升解码的速度 和设备利用率
 - ▶ 批次生成的策略:常以句子数作为batch的度量单位
 - 当源语文本已知时,与训练类似,排序后划分batch
 - 实时翻译时, 等待一个时间段, 对期间得到的句子划 分batch
 - ▶ 批次大小的设置:根据任务合理选择
 - 批量大, GPU利用率高, 吞吐大, 短句需要等待长句
 - 实时性要求高时不适合过大批量

实验分析

深层模型

反向翻译

知识精炼

双向训练

统计机器翻译的使用